Technische Hochschule **Rosenheim**

Fakultät für Informatik

Wirtschaftsinformatik

Konzeption und Entwicklung eines KI-gestützten Chatbots zur automatischen Beantwortung von Supportanfragen unter Verwendung interner Datenquellen

Bachelor Thesis

von

Atakan Sentürk

Datum der Abgabe: tt.mm.jjjj
Erstprüfer: Prof. Dr. Marcel Tilly
Zweitprüfer: Prof. Dr. Gerd Beneken

Eigenständigkeitserklärung / Declaration of Originality

Hiermit bestätige ich, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken (dazu zählen auch Internetquellen) entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht.

I declare that I have authored this thesis independently, that I have not used other than the declared sources / resources, and that I have explicitly marked all material which has been quoted either literally or by content from the used sources.

Rosenheim, den tt.mm.jjjj

Vor- und Zuname

Kurzfassung

text

Schlagworte:

Inhaltsverzeichnis

1 Einführung **1**
- 1.1 Motivation . . . 1
- 1.2 Zielsetzung . . . 1

2 Grundlagen **2**
- 2.1 Techdivision & IT-Services . . . 2
- 2.2 Chatbots . . . 2
- 2.3 Künstliche Intelligenz . . . 4
  - 2.3.1 Machinelles Lernen . . . 4
  - 2.3.2 Neuronale Netzwerke . . . 4
  - 2.3.3 Training . . . 6
- 2.4 LLMs . . . 6
  - 2.4.1 Tokenizer . . . 8
  - 2.4.2 Training . . . 9
  - 2.4.3 Hypertraining . . . 9
  - 2.4.4 Inference . . . 9
  - 2.4.5 Prompting . . . 9
  - 2.4.6 Encoder-Decoder Architektur . . . 9
- 2.5 Transformer . . . 10
  - 2.5.1 Attention Mechanismus . . . 10
- 2.6 Vektor Datenbanken . . . 10
- 2.7 Embeddings . . . 10
- 2.8 RAG . . . 10
  - 2.8.1 Advanced RAG . . . 12
  - 2.8.2 Modular RAG . . . 13
- 2.9 Ragas . . . 13
- 2.10 Langchain . . . 13
- 2.11 Huggingface . . . 13
- 2.12 llama.cpp & Ollama . . . 13
- 2.13 Google . . . 13
  - 2.13.1 Google Cloud . . . 13
  - 2.13.2 Google Chat . . . 13

3 Anforderungen **14**
- 3.1 Anforderungsanalyse . . . 14

4 Konzeption **15**
- 4.1 Auswahl der Chatmodelle . . . 15
- 4.2 Auswahl der Embedding Modelle . . . 16
- 4.3 Prompting . . . 16
- 4.4 Auswahl der Vektor Datenbank . . . 16

4.5 Architektur des Systems 16

5 Entwicklung **17**

A Erstes Kapitel des Anhangs **18**

Literaturverzeichnis **19**

Abbildungsverzeichnis

2.1 Neuron eines Neuronalen Netzwerks 5
2.2 Neuronale Netz 7
2.3 Neuronale Netz 8
2.4 LLM Google Trends 9
2.5 Transformer Architektur 11

Tabellenverzeichnis

Abkürzungen

LLM Large Language Model

NLP Natural Language Processing

1 Einführung

1.1 Motivation

Die Techdivision ist intern in sogenannten Services strukturiert, die häufig ein intensives Zusammenarbeiten erfordern. Diese Zusammenarbeit findet über verschiedene Kommunikationskanäle statt, darunter JIRA Boards und Support-Chats. Oft werden Routinefragen gestellt, die automatisiert werden könnten.

Durch den Aufstieg von verschiedenen textbasierten Chat-Modellen wie OpenAIs ChatGPT oder Googles Gemini, hat man in den letzten Jahren gesehen, zu was Modelle inzwischen in der Lage sind. Sie sind nicht mehr nur in der Lage, mit Menschen zu kommunizieren, sondern helfen diesen auch bei ihren Jobs oder Schulangelegenheiten. Verschiedene trainierte Modelle sind inzwischen in der Lage, komplizierte Probleme zu lösen und Menschen das Leben einfacher zu machen.

Dadurch stellt sich speziell in den Support-Chats die Frage, wie viele der Supportanfragen sich durch einen KI-gesteuerten Chatbot ohne Hilfe eines Mitarbeiters lösen lassen würden und inwiefern ein Chatbot zur Entlastung der Teams und zur schnelleren Lösung von Problemen beitragen könnte. Durch die Automatisierung einfacher Supportanfragen könnte zum einen Zeit gespart, zum Anderen auch die Ressourcen der Teams effektiver genutzt werden. Mitarbeiter könnten sich verstärkt auf die schwierigeren Supportanfragen konzentrieren, während der Chatbot die repetitiven und einfachen klärt, was nicht nur das Team entlastet, sondern auch die Reaktionszeit auf Supportanfragen erhöht.

1.2 Zielsetzung

Das Ziel der Arbeit besteht darin, einen Chatbot zu konzipieren und einen Prototyp zu entwickeln, der mit Hilfe der Daten der internen Datenquellen der Techdivision Support leistet und Routinefragen beantwortet. Der Chatbot soll idealerweise innerhalb von Google Chat integriert werden. Dabei ist es wichtig, dass der Chatbot, statt in Einzelchats, in einer Chat Gruppe läuft. Diese beinhaltet neben den Support Suchenden, ebenfalls Mitarbeiter des jeweiligen Services. Auf diese Weise kann, falls notwendig, extern Eingegriffen werden. Außerdem sollte der Chatbot in der Lage sein zu überprüfen, wie viele der aktuellen Supportanfragen er eigenständig beantworten oder lösen kann. Falls der Chatbot keine Antwort auf eine Anfrage haben sollte, soll er in den angebundenen Datenquellen nachschlagen können, um mit dem Wissen seine Wissensbasis zu erweitern und die Fragen entsprechend zu beantworten.

2 Grundlagen

2.1 Techdivision & IT-Services

TD kurz vorstellen Die Techdivision ist ein Unternehmen, welches 2007 in Kolbermoor, Deutschland gegründet wurde. Der Grundstein für die Firma wurde aber bereits 1997 in der Garage von Tim Wagner, dem aktuellen CTO, gelegt. Zusammen mit Thomas Kalteis begann hier eine kleine Technologie-Schmiede. Im Jahr 2007 wurde daraus eine GmbH, gegründet von den Brüdern Stefan und Josef Willkommer.

2.2 Chatbots

Laut Wikipedia ist ein Chatbot "ein Chatbot oder kurz Bot ein textbasiertes Dialogsystem, das Chatten mit einem technischen System erlaubt" [Cha24]. Es gibt verschiedene Arten von Chatbots, diese unterscheiden sich aber in der Art und Weise, wie sie auf die Eingaben des Nutzers antworten. Chatbots haben einen Bereich zur Texteingabe und einen Bereich, in dem sie ihre Ausgabe darstellen können. Mit den meisten Chatbots kann man heutzutage über die natürliche menschliche Sprache kommunizieren und sie versuchen auf dieselbe Art und Weise zu antworten. Mit einigen Chatbots kommuniziert man jedoch über Befehle, die dann eine Aktion hervorrufen.

Die Generation des Textes eines Chatbots kann in drei verschiedene Kategorien untergeordnet werden: Retrieval based, generation based und rule based. Wir können beobachten, wie sich diese drei Kategorien im Laufe der Zeit entwickeln.

Im Jahr 1950 hat Alan Turing den Turing Test vorgeschlagen, bei dem es darum geht zu erkennen, ob eine Maschine das gleiche Denkvermögen hat wie ein Mensch. Bei diesem Test werden einem Tester zwei Gesprächspartner vorgelegt, von denen einer ein Mensch und der andere eine Maschine ist. Der Tester führt dann ein Gespräch mit beiden Gesprächspartnern und befragt diese. Nach der Befragung wird überprüft, ob der Tester in der Lage ist, zu sagen, welcher der Partner eine Maschine ist. Falls der Tester nicht in der Lage ist zu erkennen, welcher der Partner die Maschine ist, gilt der Turing Test als bestanden und die Maschine ist laut Turing intelligent. Es gibt Kritik am Turing Test, welche der Meinung ist, dass der Test die Maschine nur auf ihre Funktionalität getestet und nicht wirklich auf Intelligenz. Ein weiterer Kritikpunkt, den Menschen an dem Turing Test haben, ist, dass einige Menschen der Meinung sind, dass der Test eher die menschliche Leichtgläubigkeit testet, als die Intelligenz der Maschine. Viele sind der Meinung, dass dieser Test die Grundsteine für die Idee der Chatbots gelegt hat.

Die Geschichte der Chatbots beginnt in den 1960er Jahren mit dem ersten Chatbot aus dem Jahr 1966. Damals waren die Chatbots rule based. Der Name des Chatbots war ELIZA und er wurde von Joseph Weizenbaum am MIT entwickelt. Weizenbaum hat fünf Grundprobleme aufgestellt, welche er bekämpfen musste für die Entwicklung von ELIZA. Die Probleme waren:

1. Die Identifikation von Stichwörtern

2. Das Finden des minimalen Kontexts
3. Die Auswahl der geeigneten Transformation
4. Generation von Antworten bei Abwesenheit von Stichworten
5. Bearbeitung der Eliza Skripte

[Wei66].

ELIZA wurde so entwickelt, dass sie versucht hat, menschliche Sprache zu imitieren, indem sie den eingegebenen Text nach Stichwörtern durchsucht. Stichwörter sind Wörter, denen besonders hohe Wichtigkeit laut dem ELIZA-Script gegeben wurde. Es lässt sich vermuten, dass hierbei besonders Wörter mit einem hohen Informationsgehalt verwendet wurden. Jedes Stichwort hatte noch einen sogenannten RANK, welcher die Wichtigkeit des jeweiligen Stichworts im Vergleich zu anderen Stichworten festgelegt hat. Nachdem die Stichwörter entdeckt wurden, geht es weiter mit einer sogenannten “Transformation Rule”. Diese besteht aus einer Zerlegungs-Phase und einer Zusammensetzungs-Phase. Es gibt verschiedene Regeln für beides. Anhand der Syntax wird ausgemacht, welche Regel für die Zerlegung in Frage kommt und anhand dieser wird dann die Zusammensetzung ausgemacht. /Vllt mehr dazu vllt weniger?/. Es gibt anekdotische Hinweise von Weizenbaum und seinem Team darauf, dass es Teilnehmer gab, die eine emotionale Bindung zu seinem System aufgebaut haben. Eliza verhält sich wie ein Psychotherapeut. Das heißt, der Nutzer beginnt das Gespräch und Eliza greift Punkte hauptsächlich aus den Eingaben des Nutzers auf, ohne großen Zusammenhang mit Themen außerhalb dieses Gesprächs. Der Bot kennt keinen Kontext sondern antwortet, je nach seinem aktuellen Skript auf den aktuellen Satz. Selbst Weizenbaum selbst hat scheinbar mit der Eröffnung in seine Arbeit gezeigt, dass er selbst nicht der Meinung war, dass ELIZA wirklich ein intelligentes System ist:

Er ist der Meinung, dass Programme im Bereich der künstlichen Intelligenz und im Bereich des heuristischen Programmierens so aufgebaut sind, dass sie auf wundersame Weise funktionieren, sodass sie selbst erfahrene Beobachter faszinieren. Aber sobald man herausfindet, wie diese Programme funktionieren, verlieren sie ihre Magie und es entarnt sich als nichts mehr als eine Reihe von Anweisung, die alleine betrachtet sehr simple sind. Das Ziel seiner Forschungsarbeit ist es, die Magie hinter Eliza zu enttarnen, da er der Meinung ist, dass es wenig andere Dinge gibt, die diese Enttarnung so sehr nötig hatten, wie Eliza[Wei66].

Nach Eliza kam ein Chatbot namens Parry der an der Stanford University entwickelt wurde. Während Eliza eher einen Psychotherapeuten imitiert hat, hat Parry einen Patienten mit paranoider Schizophrenie imitiert. Dieser Bot war im Jahr 1979 Teil eines Experiments, der einem Turing Test gleicht. Hier wurden verschieden Psychotherapeuten vor Bildschirme gesetzt und mussten erraten, ob die gegenüber gestellten Aussagen von einem echten Schizophrenen Patienten kommen oder von einem Chatbot. Teil des Experiments waren 5 Psychiater die jeweils 2 "Patientenßur Beurteilung bekommen haben. Der erste lag bei beiden richtig, der zweite lag bei beiden falsch. Der dritte dachte beide Patienten sind echte Patienten und die letzten zwei dachten beide sind Chatbots. Das Problem hierbei war, dass der Pool an Probanden mit 5 Psychiatern sehr klein war. Dazu kommt noch der Fakt, dass Patienten mit Schizophrenie ein gewisses Level an Unverständlichkeit in ihren Konversationen haben, welches die Beurteilung, ob es generell ein guter Chatbot erschwert. Heute wird Parry eher als ein schwacher Chatbot gesehen, da er nicht von Konversationen lernen kann, keinen richtigen Kontext hat und sehr langsam ist. Natürlich ist ein Teil davon abhängig von den technischen

Limitationen die es damals gab, aber es ist dennoch wichtig zu beachten[Ada20]. 1995 wurde der Internet Chatbot ALICE veröffentlicht. Er war im Internet zu finden und er wurde als Open Source Software veröffentlicht, hat aber nicht viele Mitentwickler gefunden, bis die Software im Jahre 1998 von der Programmiersprache SETL auf die Programmiersprache Java gewechselt ist. Das Problem war, dass SETL eine eher unbekannte Sprache war. Im Laufe der Jahre wurde das Projekt mehrmals mit verschiedenen Preise ausgezeichnet, wie beispielsweise dem Loebner Prize. Dieser Bot wurde von Weizenbaums Eliza inspiriert und war selbst die Inspiration für den Film "Her", in der die Beziehung zwischen Menschen und Maschinen beleuchtet wird[Mor13]. Alice hatte eine viel größere Sammlung an Keywords, auf die sie reagieren konnte als Eliza, aber von den Grundprinzipien her, hat sie auf die selbe Art und Weise Keywords in den Eingaben des Nutzers gesucht und dann je nach ihren Datenbankeinträgen darauf geantwortet [Ada20].

2.3 Künstliche Intelligenz

Künstliche Intelligenz ist ein Teil der Informatik der sich damit beschäftigt, Aufgaben, die früher menschliche Intelligenz benötigt hat, von Maschinen bzw. Computern übernehmen zu lassen. Zu den Aufgaben gehören unter anderem:

- Erkennen von Mustern
- Treffen von Entscheidungen
- Verstehen von Sprache

Durch Fortschritte in der künstlichen Intelligenz konnten Forstschritte in all diesen Aufgabenbereichen erreicht werden. Die verschiedenen Aufgaben werden teils in verschiedenen Teilbereichen der künstlichen Intelligenz behandelt. Ein paar der Teilbereiche sind:

- Computer Vision
- Natural Language Processing
- Robotik

2.3.1 Machinelles Lernen

2.3.2 Neuronale Netzwerke

Neuronale Netze sind ein Teil des Maschinellen Lernens, welche versucht sich stark an dem Aufbau eines biologischen Gehirns zu orientieren. Dementsprechend bestehen sie aus Tausenden oder sogar Millionen “Neuronen”, welche durch Knotenpunkte dargestellt werden. Diese “Neuronen” sind stark miteinander verbunden. Sie sind über verschiedene Reihen miteinander verbunden, wie in der Abbildung 2.1 dargestellt.

Jeder Eingang an einem Neuron hat eine Gewichtung. Wenn die Gewichtung eines Eingangs 0 ist, dann heißt es, dass zwei Knoten keine Verbindung miteinander haben. Wenn die Gewichtung positiv ist, dann hat es eine bestärkende Wirkung und, falls die Gewichtung negativ ist, dann hat es eine hemmende Wirkung.

Jedes Neuron hat zudem einen sogenannten Bias, der Bias wird benötigt, damit man die Aktivierungsschwelle der Aktivierungsfunktion verschieben kann. Dies sorgt für eine

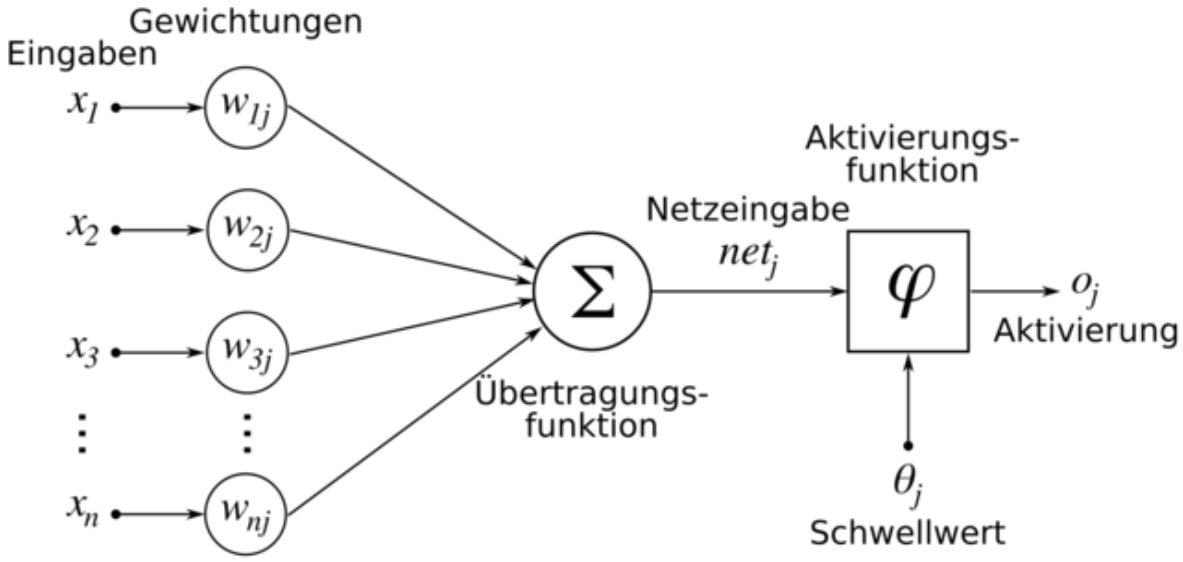


Abbildung 2.1 Neuron eines Neuronalen Netzwerks

erhöhte Flexibilität, da der Wert der Aktivierungsfunktion ohne den Bias immer null wäre, wenn alle Eingaben null sind. Durch den Bias hat das Neuron also eine Grundaktivität, welche während dem Training angepasst werden kann, damit die Ergebnisse besser für den eigenen Fall werden. Das aktuelle Neuron summiert dann alle gewichteten Werte und addiert den Bias. Wie in dieser Formel dargestellt:

$$\sum_i w_i x_i + b$$

Der summierte Wert wird durch die Aktivierungsfunktion transformiert und das Ergebnis wird dann dem nächsten Neuron in der nächsten Schicht weitergeleitet. Typische Aktivierungsfunktionen sind

- Sigmoid Function :
$$f(x) = \frac{1}{1 + e^{-x}}$$
- ReLu (Rectified Linear Unit):
$$f(x) = \max(0, x)$$
- Tanh:
$$f(x) = tanh(x)$$

[Kem23]

Die zwei Schichten die es immer gibt sind die Eingabe Schicht und die Ausgabe Schicht. Dazwischen kann es verstecke Schicht geben, die benötigt werden um komplexere Zusammenhänge zu bearbeiten, muss es aber nicht. Die Eingabe Schicht erhält die Eingabedaten von außen und gibt diese dann weiter an die nächste Schicht. Als nächstes werden die Daten weiter an eine verborgene Schicht gegeben, die die Werte dann bearbeitet. Es gibt X verschieden verborgene Reih in einem Neuronalen Netzwerk. Die Anzahl der Reihen und die Anzahl der Neuronen pro versteckter Schicht kann sich unterscheiden. Es gibt hierbei

keine allgemeingültige Größe, die für alle Fälle passt. Stattdessen kommen hierbei Erfahrung und Experimentation ins Spiel.

Es kann sogar sein, dass gar keine versteckte Reihen notwendig sind, wenn das Model linear seperierbar ist. Das liegt daran, dass ein Modell ohne versteckte Schichten bereits in der Lage ist diese Grenze zu erlernen und die Daten dann korrekt zu klassifizieren.

Die Anzahl der Neuronen schwankt zwischen verschiedenen Neuronalen Netzen und auch innerhalb eines Neuronalen Netzes schwankt die Anzahl der Neuronen zwischen den verschiedenen Schichten. Bei der Eingabe Schicht kommt es auf die Trainingsdaten an, diese legen die Anzahl der Neuronen fest. Um genau zu sein, kommt es auf die Anzahl der Features an, die die Trainingsdaten beinhalten. Bei einem Neuronalen Netz, welches mit Daten aus einer normalen Tabelle trainiert wird, ist das beispielsweise die Anzahl der Spalten, bei einem bei einem Neuronalen Netz, welches mit Bildern trainiert werden soll, könnten das die einzelnen Pixel des jeweiligen Bildes sein.

[Kri22] Die Anzahl der Neuronen in der Ausgabe Schicht kommt darauf an, welche Art von Modell man betrachtet. Es wird hier vor allem zwischen zwei verschiedenen Arten unterschieden. Die zwei Arten die es gibt sind Regressoren und Klassifikatoren. Bei Regressoren gibt es ein Ausgabe Neuron. Bei Klassifikatoren kann es mehrere geben.

Regressoren ordnen die Ergebnisse im Regelfall in eine von zwei Optionen ein. Der Wert den das Modell berechnet ist ein Wert zwischen 0 und 1. Aber die Ausgabe des Neuronalen Netzes ist entweder eins oder null. Hierbei gibt es einen Schwellenwert, der, wenn er überschritten wird, die Ausgabe des Modells auf eins bringt und, wenn dieser Wert nicht überschritten wird, ist die Ausgabe null. Ein Regressor klassifiziert die Daten in eine von zwei Gruppen, wenn der Wert null ist, gehört die Eingabe in eine Gruppe und bei eins in die jeweils andere.

Beispiele hierfür sind:

- Gesichtserkennung
- Stimmerkennung
- Spamfilter in emails

Die Klassifikatoren haben ein oder auch mehrere Ausgabe Neuronen. Die Anzahl der Neuronen kommt auf die Anzahl der möglichen Ausgaben an. Beispielsweise könnte man ein System betrachten, welches lernen soll, welche Art von Fahrzeug auf einem Bild dargestellt ist. In der Abbildung 2.2 ist ein simpler Decision Tree dargestellt. Anhand dieser kann man sehen, welche Optionen es als Asugaben gibt. In dieser Situation hätte die Ausgangs Schicht drei Neuronen, da es drei mögliche Ausgaben gibt.

2.3.3 Training

Um ein Modell nach der

2.4 LLMs

Large Language Models sind eine Art der künstlichen Intelligenz, welche mithilfe probalistischer Methoden Text generiert. Im Grunde sind diese LLMs Text Vervollständigungsgeneratoren. Heutzutage basieren Chatbots auf sogenannten Large Language Models. LLMs sind in ihrem Kern nur 2 Dateien. Eine Datei die die sogenannten Gewichte des Neural

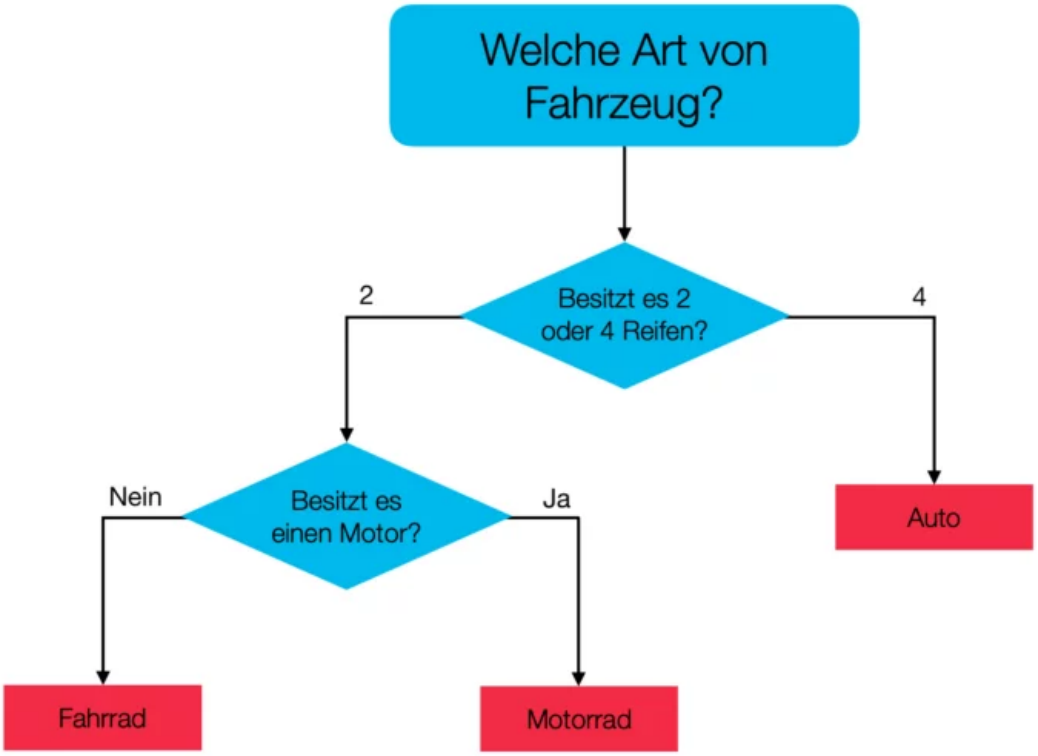


Abbildung 2.2 Neuronale Netz

Networks beinhaltet, welche beim Trainieren entstanden sind und eine Datei, welche den Code beinhaltet,damit man dieses Neural Network ausführen kann. Der Code lässt sich in ein paar hundert Zeilen Code schreiben, selbst ohne Abhängigkeiten. Der größere und aufwändigere Part sind die Gewichte. Die Gewichte entstehen, beim trainieren des Neural Networks, welches auf der Transformer - Decoder Architektur basiert, welche 2017 im Paper Äll you need is attention"vorgestellt wurde. Der genaue Stack den bspw. OpenAI heutzutage benutzt ist nicht bekannt, aber wir wissen, dass dieser ebenfalls auf der Transformer Architektur basiert. Wir sehen anhand der 2.4, welche über Google Trends das Interesse am Wort "LLMïm Verlauf der letzten 5 Jahre darstellt, dass das Interesse an Large Language Models besonder stark im Dezember 2022 angestiegen ist und seitdem immer weiter steigt. Die Daten von Google Trends sind normalisiert zwischen 0 und 100 also können wird dadurch zwar keine genauen Angaben machen, wir sehen aber, dass das Wachstum stetig am steigen ist.

Im Grunde sind die LLMs die hinter Chatbots wie ChatGPT von OpenAI und LeChat von MistralAI sogenannte GPTs. Wenn man den Begriff aufteilt sieht man was dahinter steckt. GPT steht für Generative pretrained Transformer. Generative steht für die Art und Weise auf der diese LLM ihre Ausgaben generiert, Pretrained steht dafür, dass die LLM vor ihrer Nutzung auf einer Datenmenge trainiert wurde und Transformer steht hier für die Transformer Architektur.

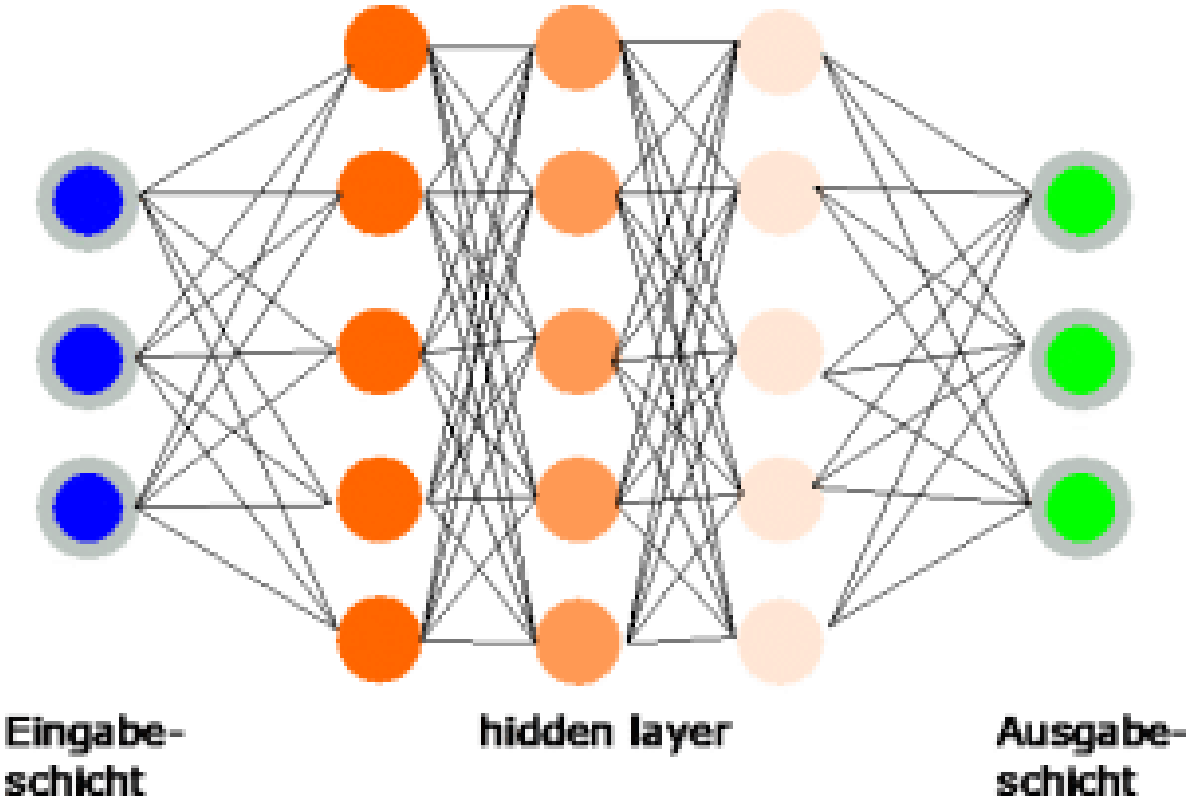


Abbildung 2.3 Neuronale Netz

2.4.1 Tokenizer

Tokenizer sind ein wichtiger Part der Machine Learning Toolchain im Zusammenhang mit dem Lernen von menschlicher Sprache. Wenn man im Bereich des Natural Language Processing ein Machine Learning trainieren möchte stellt sich die Frage, wie man Texte aufteilen kann, damit das Modell, welches trainiert wird diese verarbeiten kann.

Die Tokenizer teilen die Texte so auf, dass das zu trainierende Modell komplexe Sätze besser aufteilen und verstehen kann. Der Tokenizer macht das, indem er den Text in sogenannte Tokens aufteilt. Ein Token kann ein ganzes Wort, ein Teil eines Worts oder ein Satzzeichen sein.

Dies ist ein wichtiger Teil des Natural Language Processing (NLP), da die Aufteilung der Trainingsdaten einen großen Einfluss darauf hat, wie gut die Large Language Model (LLM) funktioniert. Genau wie bei Compilern, die Programme in Tokens aufteilen, benutzen wir bei LLM Tokenizer, damit wir die Texte aufteilen können und die dabei entstandenen Tokens über verschiedene grammatikalische Regeln zusammensetzen können.

Eines der größten Probleme hierbei ist, dass verschiedene Sprachen verschiedene grammatikalische Regeln haben und somit verschiedene Arten des Zerlegens oder Zusammensetzens brauchen. Ein weiteres Problem ist, dass das selbe Wort teils verschiedene Bedeutungen haben kann. Hierbei ist der Kontext wichtig und die Anzahl der Tokens, die das Modell erkennen kann. Man könnte hierbei alle möglichen Token aufnehmen, was aber dafür sorgen kann, dass das System overfitted beim Training. Dazu kommt, dass das die notwendigen Kosten zum Trainieren und für die Inference des Systems erhöhen würde.[Per21] [Che16]

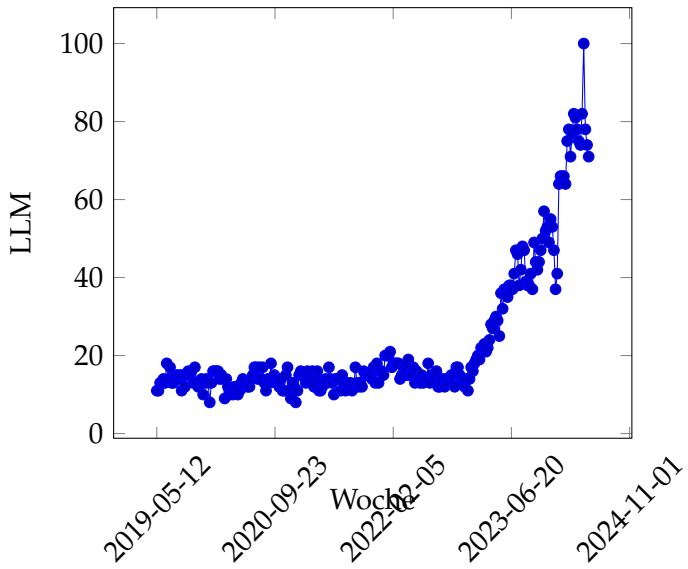


Abbildung 2.4 LLM Google Trends

2.4.2 Training

Der erste Schritt um eine LLM zu erstellen ist es diese zu trainieren. Die LLM trainieren heißt in diesem Fall die LLM mit Daten zu trainieren. Dafür werden viele verschiedene Daten gesammelt und die LLM wird dann mit Hilfe dieser Daten trainiert.

Die LLM teilt in diesem Prozess die Daten die sie erhalten hat mit Hilfe eines Tokenizers in verschieden Tokens ab und lernt in diesem Zusammenhang, den Aufbau menschlicher Sprache in der jeweiligen Sprache, die zum trainieren verwendet wird.

2.4.3 Hypertraining

2.4.4 Inference

Sobald ein Model trainiert wurde und bereit ist benutzt zu werden, muss man es ausführen. Dieser Prozess nennt sich Inference. Um Inference ausführen zu können gibt es heutzutage verschiedene Möglichkeiten. Es gibt zwar die Möglichkeit Inference über online APIs wie beispielsweise die Huggingface Inference API [Ser] oder ähnliche Services auszuführen, wir behandeln hier aber nur lokale Optionen.

Das Hauptproblem bei der Inference von diesen Modellen war zu Beginn, dass sie sehr viele Ressourcen benötigt haben und nur über spezielle Hardware ausführbar waren. Spezielle Hardware heißt in diesem Fall, dass sie zu Beginn nur über Grafikkarten mit sehr viel VRAM nutzbar waren.

2.4.5 Prompting

2.4.6 Encoder-Decoder Architektur

Bevor auf die Transformer Architektur eingegangen werden kann, muss auf die vorangeganen Architekturen eingeganen werden. Diese Technologien haben sich damals vorallem im Kontext des Sequence-to-Sequence Learnings weiterentwickelt. Sequence-to-Sequence

Learning oder kurz Seq2Seq Learning, bringt eine Sequenz variabler Länge in eine andere Sequenz variabler Länge.[Sut14] Beispiele hierfür wären Text Zusammenfassungen und Übersetzungen. Die Architektur aus der sich der Transformer, der in dem Abschnitt 2.5 behandelt wird, der in den LLMs heutzutage verwendet wird, entwickelt hat, ist die Encoder - Decoder Architektur.

Die Encoder-Decoder Architektur besteht aus zwei Rekurrenten Neuralen Netzen. Wie ein Neurales Netz funktioniert wurde bereits im Abschnitt 2.3.2 behandelt. Das besondere an einem Rekurrenten Neuralen Netz ist, dass dieses die vorherigen Aktivierungen der einzelnen Neuronen mit berücksichtigt. Dadurch, dass die vorangeganen Aktivierungen ebenfalls beachtet werden, können Kontexte erkannt werden und Sätze können sinnvoll übersetzt werden.

Hierbei erhählt der Encoder eine Eingabe Sequenz, welche dann Kontext Vektoren erstellt, welcher vom Decoder in eine Ausgabe Sequez umgewandelt wird. Das Problem bei der originalen Encoder-Decoder Architektur ist, dass die Vektoren eine festgesetzte Größe hatten und

2.5 Transformer

Die Technologie auf der die heutigen LLMs im Grunde basieren ist die sogenannte Transformer Technologie.

Diese Architektur wurde im Research Paper Ättention is all you needïm Jahr 2017 von Google Forschern vorgestellt. Laut ihrer Forschung behaupteten sie, dass ihre neue Architektur signifikant weniger Zeit zum Training braucht, während es besser parallelisierbar ist und die Ergebnisse trotzdem besser sind. Nach 3.5 Tagen Training auf nur 8 Grafikkarten hat ihr Modell einen neuen Single Model Rekord aufgestellt in der WMT 2014 Englisch-zu-Französisch Übersetzungsaufgabe[Vas23]. Von Yuening Jia - DOI:10.1088/1742-6596/1314/1/012186, CC BY-SA 3.0, https://commons.wikimedia.org/w/index.php?curid=121340680

2.5.1 Attention Mechanismus

Die Grundidee auf die die Transformer aufbauen ist die des Attention Mechanism, welcher 2014 im Paper “Neural Machine Translation by Jointly Learning to Align and Translate” von Bahdanau et al. vorgestellt wurde. Beim Attention Mechanism geht es darum, Deep Learning Modelle zu verbessern, indem Der Attention Mechanism basiert [Bah16]

2.6 Vektor Datenbanken

Vektor Datenkbanken sind die Datenbanken.

2.7 Embeddings

2.8 RAG

Eines der größten Probleme der LLMs heutzutage ist, dass die Informationen, die sie zum beantworten für Fragen benutzen, teilweise veraltet sind oder sehr allgemein. Ein weiteres großes Problem ist die im Abschnitt 2.4 genannte Halluzination, die passieren kann, wenn

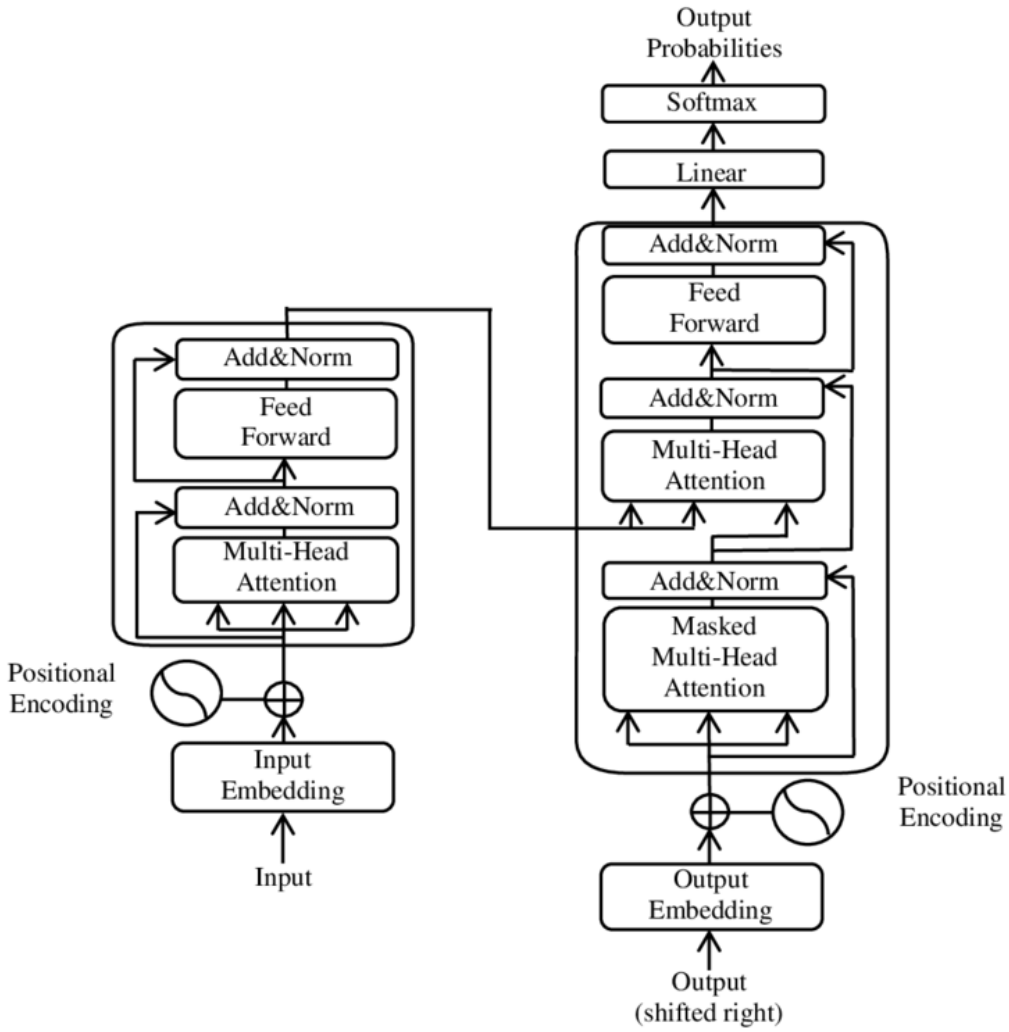


Abbildung 2.5 Transformer Architektur

eine LLM eine Frage zu der es eigentlich nichts weiß, beantwortet. Eine Technologie, die versucht, dieses Problem zu beseitigen, ist die sogenannte Retrieval Augmented Generation. Die Retrieval Augmented Generation soll das parametrische Gedächtnis der LLM mittels eines nicht parametrischen Gedächtnisses erweitern.[Lew21]

Retrieval Augmented Generation löst ein paar Probleme vor denen LLMs heutzutage stehen, ist aber keine perfekte Lösung und muss sich auch seinen eigenen Problemen stellen. In diesem Zusammenhang gibt kann man heute RAG in drei Stufen einordnen.[Gao24]

Naive RAG

Naive RAG ist die traditionelle Herangehensweise and das Problem der RAG. Sie besteht aus drei Stufen. Indexing(Indizierung??), Abfrage und Generierung.

Beim Indizieren werden die rohen Eingabedaten gereinigt und extrahiert. Dies ist wichtig, da es verschieden Formate haben kann, bei Textdaten gibt es bspw. PDF Dateien, Markdown oder HTML. Diese Texte werden nach der Reinigung in Plain Text umgewandelt und

dieser Plain Text wird dann in kleinere Teile unterteilt . Diese kleineren Parts werden dann über ein Embedding modell in eine Vektordarstellung umgewandelt und dann in einer Vektordatenbank abgespeichert.

Bei der Abfrage erhält das RAG System eine Anfrage und benutzt das selbe Embedding Modell, wie in der Indizierungsphase, um die Abfrage in eine Vektordarstellung umzuwandeln. Im Anschluss wird durch einen Semantischen Vergleich nach den Top-k Ergebnissen gesucht und diese werden dann ausgegeben.

Bei der Generation bekommt die LLM dann die Abfrage und die ausgegeben Ergebnisse in einem Prompt zurück und generiert daraus dann eine Antwort. Was genau hier beachtet wird kommt auf die LLM, das Kontext Fenster und den benutzten Prompt an[Gao24].

Wie in 2.8 bereits erwähnt gibt es hierbei ein paar Probleme. Das Hauptproblem, welches hier besteht ist die der Abfrage. Bei der Abfrage gibt es oft Probleme, welche mit der Genauigkeit zu tun haben. Dementsprechend kann es passieren, dass das RAG System falsche oder unpassende Informationen zurück gibt. Aufgrund der Probleme bei der Abfrage entstehen dann ebenfalls Probleme bei der Generation der Antwort. Was dazu führt, dass die Qualität der Antworten sinkt. Dadurch sinkt dann ebenfalls die Verlässlichkeit auf das System.

2.8.1 Advanced RAG

Advanced RAG wurde entwickelt um den Problemen der naiven RAG entgegenzuwirken bzw. sie zu beseitigen. Dementsprechend werden hier einige Dinge geändert. Vorallem in der Stufe der Abfrage wurde hier einiges geändert. Um die Qualität zu erhöhen wurden der Abfrage pre- und post Strategien hinzugefügt. Dazu wurde der Indexing Prozess angepasst. Beim Indexing wird nun Metadata mit eingebunden und der Text wird genauer unterteilt. Pre-retrieval: Beim pre-retrieval wird vorallem darauf geachtet die Anfrage so klar wie möglich zu machen. Hierfür werden Metadaten angehängt, Anfragen umgewandelt, Anfragen erweitert und noch einige weitere Dinge abgeändert. Das Ziel hier ist es die Anfrage zu ändern, sodass sie so klar wie möglich ist und sie für Retrival zu optimieren.

Post Retrieval: Nachdem der Kontext nach dem Retrieval Prozess abgefragt wurde, wird versucht die abgerufenen Daten möglichst optimal mit der Anfrage zu verbinden. Hierfür werden vorallem das komprimieren und das neu Anordnen des Kontexts verwendet. Die wichtigsten Dokumente werden an eines der Enden der Anfrage geschoben und es wird versucht die wichtigsten Informationen heraus zu suchen und nur diese zurück zu geben. Dadurch sollte die LLM genug Informationen erlangen, aber nicht zu viele und die Antworten sollten besser werden.

2.8.2 Modular RAG

2.9 Ragas

2.10 Langchain

2.11 Huggingface

2.12 llama.cpp & Ollama

Ein Problem, welches

2.13 Google

2.13.1 Google Cloud

Dadurch, dass die Techdivision ein Google Partner ist und intern versucht möglichst viele Produkte von Google zu nutzen

2.13.2 Google Chat

Google Chat ist eine von Google entwickelte Chatplattform. Diese Plattform hat 2017 Google Hangout zusammen mit Google Meet ersetzt. Zu Beginn war das Projekt nur im Zusammenhang mit Google Workspace erhältlich und somit war es eine Chatplattform die hauptsächlich für Teams und Unternehmen benutzbar war. 2021 wurde die Plattform im Early Access auch für normale Benutzer erreichbar gemacht und ist seit 2022 für jeden benutzbar.

Diese Plattform ist die Plattform, die die Techdivision hauptsächlich intern zur Kommunikation benutzt. Es gibt auf der einen Seite 1 zu 1 Chat in der eine Person mit nur einer anderer Person kommuniziert und auf der anderen Seite gibt es Innerhalb dieses Services die Möglichkeit sogenannte Spaces zu erstellen, welche Gruppenchats ähneln. Ein Teil dieser Gruppenchats sind die in 2.1 genannten Supportchats in die der Chatbot final eingebaut werden soll.

3 Anforderungen

3.1 Anforderungsanalyse

Es gibt fünf Punkte die laut Experteninterviews gefordert sind.

1. Der Bot soll lokal laufen aufgrund von Datenschutz
2. Der Bot soll in einer Chatgruppe laufen, damit IT-Supportmitarbeiter eingreifen können, falls nötig
3. Der Bot soll Unternehmensdaten verwenden
4. Der Bot soll mit der Zeit auf neues Wissen zugreifen können
5. Der Bot soll auf Deutsch arbeiten
6. Der Bot soll Anfragedaten speichern können, damit falls notwendig Kurse zu bestimmten Themen gegeben werden können oder bestimmte Personen ein FAQ Termin kriegen

4 Konzeption

Bevor mit der Entwicklung begonnen werden kann, muss das Konzept erstellt werden. Zur Konzeption gehört in dieser Arbeit, die Auswahl der technischen Werkzeuge, die Programmiersprache, die Umgebung und die Modelle die benutzt werden sollen.

4.1 Auswahl der Chatmodelle

Nach der Analyse beginnt die Konzeption. Die erste Frage, die beantwortet werden muss, ist, welche Modelle werden benutzt. Es werden Modelle an zwei Stellen benötigt. Die erste Frage ist, welches Modell soll generell für den Chatbot benutzt werden. Hier gibt es ein paar Möglichkeiten. Die Anforderung die hier relevant ist, ist die Anforderung Nummer 1. Da der Bot lokal laufen sollte, werden keine Modelle benutzt, die nur über eine externe API erreichbar sind, wie beispielsweise OpenAIs ChatGPT, um Datensicherheit sicherzustellen. Also ist die einzige Option ein Modell zu downloaden und mit diesem zu interagieren. Hier gibt es zur Zeit fast täglich neue Modelle. Viele verschieden Unternehmen und Instiutionen haben angefangen ihre eigenen Modelle oder abgewandelte Versionen größerer Modelle zu trainieren und zu veröffentlichen. Zu den bekanntesten Open Source Modellen gehören die Modelle:

1. Mistral von Mistral AI
2. Llama von Meta AI
3. Gemma von Google

Wir werden im Kontext dieser Arbeit 5 verschiedene Modelle miteinander vergleichen. Die meisten der Open Source Modelle basieren aber auf den Modellen von Meta AI und Mistral AI, das heißt sie sind finetuned Versionen von diesen. Ein Hub auf dem viele der Modelle veröffentlicht werden ist hugginface.co. Hier werden viele Open Source Modelle veröffentlicht und man kann sie downloaden und verschiedene Benchmarks, etc. einsehen.

Einige der größeren Modelle wie beispielsweise Gemma und Llama3 wurden multilingual trainiert und verstehen in ihrer Grundversion bereits teilweise beide Sprachen, die wir brauchen. Aus Speicher, Leistungs und Generationtime Gründen werden in dieser Arbeit nur Modelle unter 12B Parametern miteinander verglichen. Obwohl die oben genannten Modelle Deutsch in einem gewissen Rahmen bereits verstehen, ist in der 8B und 7B Variante der Modelle nicht sichergestellt, ob sie alles verstehen, durch die kleinere Trainingsdaten- und Parametermenge. Dementsprechend werden, wo möglich, finetuned Versionen die auf Deutsch trainiert wurden verwendet.

Zwei Organisationen die sich damit beschäftigen, Open Source Modelle auch auf Deutsch verfügbar zu machen nennen sich DiscoResearch [Dis24] und LAION LeoLM [Leo23]. LAION LeoLM hat mithilfe des Supercomputers Die Modelle die innerhalb dieser Arbeit miteinander verglichen werden sind

1. Llama3 von MetaAI

4.2 Auswahl der Embedding Modelle

Die nächsten Modelle über die man sich Gedanken machen muss sind die sogenannten Embedding Modelle. Hier werden einmal die importierten Texte für die Vektor Datenbank in eine Vektor repräsentation umgewandelt.

4.3 Prompting

Ein wichtiger Teil, den man beim Erstellen von Modellen beachten muss, ist das Prompting. Es gibt hier zwei Aspekte, die man beachten muss.

4.4 Auswahl der Vektor Datenbank

Im nächsten Schritt wird die Art des Chat Modells ausgesucht. Hier gibt es einige Möglichkeiten. Eine Möglichkeit wäre es, mittels API auf ein Modell wie Chat-GPT 4 zuzugreifen. Die Probleme hierbei sind, dass die Modelle nicht speziell mit unseren benötigten APIs/Infos vertraut sind. Wir könnten ein Modell suchen, dem wir unsere Daten schicken, aber das könnte teils Probleme mit Datenschutz geben. Durch diese Probleme fallen diese Optionen weg. Das heißt, das Modell muss lokal gehostet werden. Lokal heißt hierbei einfach auf einem Server von uns oder einem Server, bei dem man weiss, dass keiner auf die Daten zugreifen kann.

4.5 Architektur des Systems

Nachdem die Auswahl des Development Tools und des Models abgeschlossen ist, ist die nächste Frage, welche Architektur das gesamte System haben soll. Die Schnittstelle, über die der Nutzer später mit dem Chatbot kommunizieren soll, ist bestenfalls eine Schnittstelle zu Google Chat. Dies ist aber der unwichtigste Part an diesem Punkt. Notfalls kann man auch ein anderes Chat System anbinden, daher kümmern wir uns als erstes um die anderen Teile der Architektur.

Hierbei geht es um das Thema des Hinzufügens von neuem Wissen zum Chatbot. Das Problem bei einem trainierten Modell ist es, dass es keine neue Information ohne ein neues Training in seine Wissensdatenbank aufnehmen kann. Da sich die Daten in den jeweiligen APIs ständig ändern können, stellt das ein Problem dar. Hier ist aber nicht nur neue Information ein Problem, sondern auch geänderte alte. Woher soll der Chatbot wissen, dass sich irgendeine Information, die bereits in der Wissensdatenbank vorhanden ist, geändert hat. Für das Problem von neuen Informationen gibt es hier zwei Optionen. Das Modell, auf dem der Chatbot aufbaut, könnte neu trainiert werden, mithilfe der neuen Informationen. Hier sind die Fragen, wie oft es neu trainiert werden soll, wie lange dieser Prozess dauert und wie viel dieser Prozess kostet. Wir können das Modell nicht bei jedem neuen Update neu trainieren. Das würde zu lange dauern, aber das heisst dass es einen Zeitraum gibt in dem der Bot nicht die aktuellsten Informationen hat. Wir benutzen hier die vorher bereits erwähnte RAG in Kombination mit einer Vektor Datenbank.

5 Entwicklung

Nach dem Abschluss der Konzeption kann zur Entwicklung über gegangen werden.

A Erstes Kapitel des Anhangs

Wenn Sie keinen Anhang benötigen, dann bitte einfach rausnehmen.

Literaturverzeichnis

[Ada20] E. Adamopoulou und L. Moussiades. Chatbots: History, Technology, and Applications. *Machine Learning with Applications*, 2:100006, Dez. 2020.

[Bah16] D. Bahdanau, K. Cho und Y. Bengio. Neural Machine Translation by Jointly Learning to Align and Translate, Mai 2016. Comment: Accepted at ICLR 2015 as oral presentation.

[Cha24] Chatbot. *Wikipedia*, Jan. 2024.

[Che16] W. Chen, D. Grangier und M. Auli. Strategies for Training Large Vocabulary Neural Language Models. In *Proceedings of the 54th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, S. 1975–1985. Association for Computational Linguistics, Berlin, Germany, 2016.

[Dis24] DiscoResearch (Disco Research). https://huggingface.co/DiscoResearch, Mai 2024.

[Gao24] Y. Gao, Y. Xiong, X. Gao, K. Jia, J. Pan, Y. Bi, Y. Dai, J. Sun, M. Wang und H. Wang. Retrieval-Augmented Generation for Large Language Models: A Survey, März 2024. Comment: Ongoing Work.

[Kem23] C. Kempkes. Das Neuron Und Die Aktivierungsfunktion — Grundlagen Und Beispiele an Logischen Bausteinen, Apr. 2023.

[Kri22] S. Krishnan. How Do Determine the Number of Layers and Neurons in the Hidden Layer?, Aug. 2022.

[Leo23] LeoLM (LAION LeoLM). https://huggingface.co/LeoLM, Dez. 2023.

[Lew21] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-t. Yih, T. Rocktäschel, S. Riedel und D. Kiela. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks, Apr. 2021. Comment: Accepted at NeurIPS 2020.

[Mor13] B. Morais. Can Humans Fall in Love with Bots? *The New Yorker*, Nov. 2013.

[Per21] T. Perry. What Is Tokenization in Natural Language Processing (NLP)?, Febr. 2021.

[Ser] Serverless Inference API. https://huggingface.co/docs/api-inference/index.

[Sut14] I. Sutskever, O. Vinyals und Q. V. Le. Sequence to Sequence Learning with Neural Networks, Dez. 2014. Comment: 9 pages.

[Vas23] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser und I. Polosukhin. Attention Is All You Need, Aug. 2023. Comment: 15 pages, 5 figures.

[Wei66] J. Weizenbaum. ELIZA—a Computer Program for the Study of Natural Language Communication between Man and Machine. Jan. 1966.