Technische Hochschule **Rosenheim**

Fakultät für Informatik

Wirtschaftsinformatik

Konzeption und Entwicklung eines KI-gestützten Chatbots zur automatischen Beantwortung von Supportanfragen unter Verwendung interner Datenquellen

Bachelor Thesis

von

Atakan Sentürk

Datum der Abgabe: tt.mm.jjjj
Erstprüfer: Prof. Dr. Marcel Tilly
Zweitprüfer: Prof. Dr. Gerd Beneken

Eigenständigkeitserklärung / Declaration of Originality

Hiermit bestätige ich, dass ich die vorliegende Arbeit selbständig verfasst und keine anderen als die angegebenen Hilfsmittel benutzt habe. Die Stellen der Arbeit, die dem Wortlaut oder dem Sinn nach anderen Werken (dazu zählen auch Internetquellen) entnommen sind, wurden unter Angabe der Quelle kenntlich gemacht.

I declare that I have authored this thesis independently, that I have not used other than the declared sources / resources, and that I have explicitly marked all material which has been quoted either literally or by content from the used sources.

Rosenheim, den tt.mm.jjjj

Vor- und Zuname

Kurzfassung

text

Schlagworte:

Inhaltsverzeichnis

1 Einführung **1**
- 1.1 Motivation . . . 1
- 1.2 Zielsetzung . . . 1

2 Grundlagen **2**
- 2.1 Techdivision I& Services . . . 2
- 2.2 Chatbots . . . 2
- 2.3 LLMs . . . 4
  - 2.3.1 Transformer . . . 5
  - 2.3.2 Training . . . 5
  - 2.3.3 Inference . . . 6
- 2.4 Vektor Datenbanken . . . 6
- 2.5 RAG . . . 6
- 2.6 Ragas . . . 6

3 Konzeption **7**
- 3.1 Auswahl der Chatmodelle . . . 7
- 3.2 Auswahl der Embedding Modelle . . . 7
- 3.3 Prompting . . . 7
- 3.4 Auswahl der Vektor Datenbank . . . 7
- 3.5 Architektur des Systems . . . 8

4 Entwicklung **9**

A Erstes Kapitel des Anhangs **10**

Literaturverzeichnis **11**

Abbildungsverzeichnis

2.1 1.1 LLM Google Trends 4
2.2 Transformer Architektur 5

Tabellenverzeichnis

1 Einführung

1.1 Motivation

Die Techdivision ist intern in sogenannten Services strukturiert, die häufig ein intensives Zusammenarbeiten erfordern. Diese Zusammenarbeit findet über verschiedene Kommunikationskanäle statt, darunter JIRA Boards und Support-Chats. Oft werden Routinefragen gestellt, die automatisiert werden könnten.

Durch den Aufstieg von verschiedenen textbasierten Chat-Modellen wie OpenAIs ChatGPT oder Googles Gemini, hat man in den letzten Jahren gesehen, zu was Modelle inzwischen in der Lage sind. Sie sind nicht mehr nur in der Lage, mit Menschen zu kommunizieren, sondern helfen diesen auch bei ihren Jobs oder Schulangelegenheiten. Verschiedene trainierte Modelle sind inzwischen in der Lage, komplizierte Probleme zu lösen und Menschen das Leben einfacher zu machen.

Dadurch stellt sich speziell in den Support-Chats die Frage, wie viele der Supportanfragen sich durch einen KI-gesteuerten Chatbot ohne Hilfe eines Mitarbeiters lösen lassen würden und inwiefern ein Chatbot zur Entlastung der Teams und zur schnelleren Lösung von Problemen beitragen könnte. Durch die Automatisierung einfacher Supportanfragen könnte zum einen Zeit gespart, zum Anderen auch die Ressourcen der Teams effektiver genutzt werden. Mitarbeiter könnten sich verstärkt auf die schwierigeren Supportanfragen konzentrieren, während der Chatbot die repetitiven und einfachen klärt, was nicht nur das Team entlastet, sondern auch die Reaktionszeit auf Supportanfragen erhöht.

1.2 Zielsetzung

Das Ziel der Arbeit besteht darin, einen Chatbot zu konzipieren und einen Prototyp zu entwickeln, der mit Hilfe der Daten der internen Datenquellen der Techdivision Support leistet und Routinefragen beantwortet. Der Chatbot soll idealerweise innerhalb von Google Chat integriert werden. Dabei ist es wichtig, dass der Chatbot, statt in Einzelchats, in einer Chat Gruppe läuft. Diese beinhaltet neben den Support Suchenden, ebenfalls Mitarbeiter des jeweiligen Services. Auf diese Weise kann, falls notwendig, extern Eingegriffen werden. Außerdem sollte der Chatbot in der Lage sein zu überprüfen, wie viele der aktuellen Supportanfragen er eigenständig beantworten oder lösen kann. Falls der Chatbot keine Antwort auf eine Anfrage haben sollte, soll er in den angebundenen Datenquellen nachschlagen können, um mit dem Wissen seine Wissensbasis zu erweitern und die Fragen entsprechend zu beantworten.

2 Grundlagen

2.1 Techdivision I& Services

TD kurz vorstellen Die Techdivision ist ein Unternehmen, welches 2007 in Kolbermoor, Deutschland gegründet wurde. Der Grundstein für die Firma wurde aber bereits 1997 in der Garage von Tim Wagner, dem aktuellen CTO, gelegt. Zusammen mit Thomas Kalteis begann hier eine kleine Technologie-Schmiede. Im Jahr 2007 wurde daraus eine GmbH, gegründet von den Brüdern Stefan und Josef Willkommer.

2.2 Chatbots

Laut Wikipedia ist ein Chatbot "ein Chatbot oder kurz Bot ein textbasiertes Dialogsystem, das Chatten mit einem technischen System erlaubt" [Cha24]. Es gibt verschiedene Arten von Chatbots, diese unterscheiden sich aber in der Art und Weise, wie sie auf die Eingaben des Nutzers antworten. Chatbots haben einen Bereich zur Texteingabe und einen Bereich, in dem sie ihre Ausgabe darstellen können. Mit den meisten Chatbots kann man heutzutage über die natürliche menschliche Sprache kommunizieren und sie versuchen auf dieselbe Art und Weise zu antworten. Mit einigen Chatbots kommuniziert man jedoch über Befehle, die dann eine Aktion hervorrufen.

Die Generation des Textes eines Chatbots kann in drei verschiedene Kategorien untergeordnet werden: Retrieval based, generation based und rule based. Wir können beobachten, wie sich diese drei Kategorien im Laufe der Zeit entwickeln.

Im Jahr 1950 hat Alan Turing den Turing Test vorgeschlagen, bei dem es darum geht zu erkennen, ob eine Maschine das gleiche Denkvermögen hat wie ein Mensch. Bei diesem Test werden einem Tester zwei Gesprächspartner vorgelegt, von denen einer ein Mensch und der andere eine Maschine ist. Der Tester führt dann ein Gespräch mit beiden Gesprächspartnern und befragt diese. Nach der Befragung wird überprüft, ob der Tester in der Lage ist, zu sagen, welcher der Partner eine Maschine ist. Falls der Tester nicht in der Lage ist zu erkennen, welcher der Partner die Maschine ist, gilt der Turing Test als bestanden und die Maschine ist laut Turing intelligent. Es gibt Kritik am Turing Test, welche der Meinung ist, dass der Test die Maschine nur auf ihre Funktionalität getestet und nicht wirklich auf Intelligenz. Ein weiterer Kritikpunkt, den Menschen an dem Turing Test haben, ist, dass einige Menschen der Meinung sind, dass der Test eher die menschliche Leichtgläubigkeit testet, als die Intelligenz der Maschine. Viele sind der Meinung, dass dieser Test die Grundsteine für die Idee der Chatbots gelegt hat.

Die Geschichte der Chatbots beginnt in den 1960er Jahren mit dem ersten Chatbot aus dem Jahr 1966. Damals waren die Chatbots rule based. Der Name des Chatbots war ELIZA und er wurde von Joseph Weizenbaum am MIT entwickelt. Weizenbaum hat fünf Grundprobleme aufgestellt, welche er bekämpfen musste für die Entwicklung von ELIZA. Die Probleme waren: "(1) the identification of key words, (2) the discovery of minimal context, (3) the choice of appropriate transformations, (4) generation of responses in the absence of key

words, and (5) the provision of an editing capability for ELIZA ßcripts"”[Wei66].

ELIZA wurde so entwickelt, dass sie versucht hat, menschliche Sprache zu imitieren, indem sie den eingegebenen Text nach Stichwörtern durchsucht. Stichwörter sind Wörter, denen besonders hohe Wichtigkeit laut dem ELIZA-Script gegeben wurde. Es lässt sich vermuten, dass hierbei besonders Wörter mit einem hohen Informationsgehalt verwendet wurden. Jedes Stichwort hatte noch einen sogenannten RANK, welcher die Wichtigkeit des jeweiligen Stichworts im Vergleich zu anderen Stichworten festgelegt hat. Nachdem die Stichwörter entdeckt wurden, geht es weiter mit einer sogenannten “Transformation Rule”. Diese besteht aus einer Zerlegungs-Phase und einer Zusammensetzungs-Phase. Es gibt verschiedene Regeln für beides. Anhand der Syntax wird ausgemacht, welche Regel für die Zerlegung in Frage kommt und anhand dieser wird dann die Zusammensetzung ausgemacht. /Vllt mehr dazu vllt weniger?/. Es gibt anekdotische Hinweise von Weizenbaum und seinem Team darauf, dass es Teilnehmer gab, die eine emotionale Bindung zu seinem System aufgebaut haben. Eliza verhält sich wie ein Psychotherapeut. Das heißt, der Nutzer beginnt das Gespräch und Eliza greift Punkte hauptsächlich aus den Eingaben des Nutzers auf, ohne großen Zusammenhang mit Themen außerhalb dieses Gesprächs. Der Bot kennt keinen Kontext sondern antwortet, je nach seinem aktuellen Skript auf den aktuellen Satz. Selbst Weizenbaum selbst hat scheinbar mit der Eröffnung in seine Arbeit gezeigt, dass er selbst nicht der Meinung war, dass ELIZA wirklich ein intelligentes System ist:

“It is said that to explain is to explain away. This maxim is nowhere so well fulfilled as in the area of computer programming, especially in what is called heuristic programming and artificial intelligence. For in those realms machines are made to behave in wondrous ways, often sufficient to dazzle even the most experienced observer. But once a particular program is unmasked, once its inner workings are explained in language sufficiently plain to induce understanding, its magic crumbles away; it stands revealed as a mere collection of procedures, each quite comprehensible. The observer says to himself “I could have written that”. With that thought he moves the program in question from the shelf marked “intelligent”, to that reserved for curios, fit to be discussed only with people less enlightened than he. The object of this paper is to cause just such a reevaluation of the program about to be “explained”. Few programs ever needed it more”[Wei66].

Nach Eliza kam ein Chatbot namens Parry der an der Stanford University entwickelt wurde. Während Eliza eher einen Psychotherapeuten imitiert hat, hat Parry einen Patienten mit paranoider Schizophrenie imitiert. Dieser Bot war im Jahr 1979 Teil eines Experiments, der einem Turing Test gleicht. Hier wurden verschieden Psychotherapeuten vor Bildschirme gesetzt und mussten erraten, ob die gegenüber gestellten Aussagen von einem echten Schizophrenen Patienten kommen oder von einem Chatbot. Teil des Experiments waren 5 Psychiater die jeweils 2 "Patientenßur Beurteilung bekommen haben. Der erste lag bei beiden richtig, der zweite lag bei beiden falsch. Der dritte dachte beide Patienten sind echte Patienten und die letzten zwei dachten beide sind Chatbots. Das Problem hierbei war, dass der Pool an Probanden mit 5 Psychiatern sehr klein war. Dazu kommt noch der Fakt, dass Patienten mit Schizophrenie ein gewisses Level an Unverständlichkeit in ihren Konversationen haben, welches die Beurteilung, ob es generell ein guter Chatbot erschwert. Heute wird Parry eher als ein schwacher Chatbot gesehen, da er nicht von Konversationen lernen kann, keinen richtigen Kontext hat und sehr langsam ist. Natürlich ist ein Teil davon abhängig von den technischen Limitationen die es damals gab, aber es ist dennoch wichtig zu beachten[Ada20]. 1995 wurde der Internet Chatbot ALICE veröffentlicht. Er war im Internet zu finden und er wurde als Open Source Software veröffentlicht, hat aber nicht viele Mitentwickler gefunden, bis die Software im Jahre 1998 von der Programmiersprache SETL auf die Programmiersprache

Java gewechselt ist. Das Problem war, dass SETL eine eher unbekannte Sprache war. Im Laufe der Jahre wurde das Projekt mehrmals mit verschiedenen Preise ausgezeichnet, wie beispielsweise dem Loebner Prize. Dieser Bot wurde von Weizenbaums Eliza inspiriert und war selbst die Inspiration für den Film "Her", in der die Beziehung zwischen Menschen und Maschinen beleuchtet wird[Mor13]. Alice hatte eine viel größere Sammlung an Keywords, auf die sie reagieren konnte als Eliza, aber von den Grundprinzipien her, hat sie auf die selbe Art und Weise Keywords in den Eingaben des Nutzers gesucht und dann je nach ihren Datenbankeinträgen darauf geantwortet [Ada20].

2.3 LLMs

Heutzutage basieren Chatbots auf sogenannten Large Language Models. LLMs sind in ihrem Kern nur 2 Dateien. Eine Datei die die sogenannten Gewichte des Neural Networks beinhaltet, welche beim Trainieren entstanden sind und eine Datei, welche den Code beinhaltet, damit man dieses Neural Network ausführen kann. Der Code lässt sich in ein paar hundert Zeilen Code schreiben, selbst ohne Abhängigkeiten. Der größere und aufwändigere Part sind die Gewichte. Die Gewichte entstehen, beim trainieren des Neural Networks, welches auf der Transformer - Decoder Architektur basiert, welche 2017 im Paper Äll you need is attention"vorgestellt wurde. Der genaue Stack den bspw. OpenAI heutzutage benutzt ist nicht bekannt, aber wir wissen, dass dieser ebenfalls auf der Transformer Architektur basiert. Wir sehen anhand der Grafik 2.1, welche über Google Trends das Interesse am Wort "LLMïm

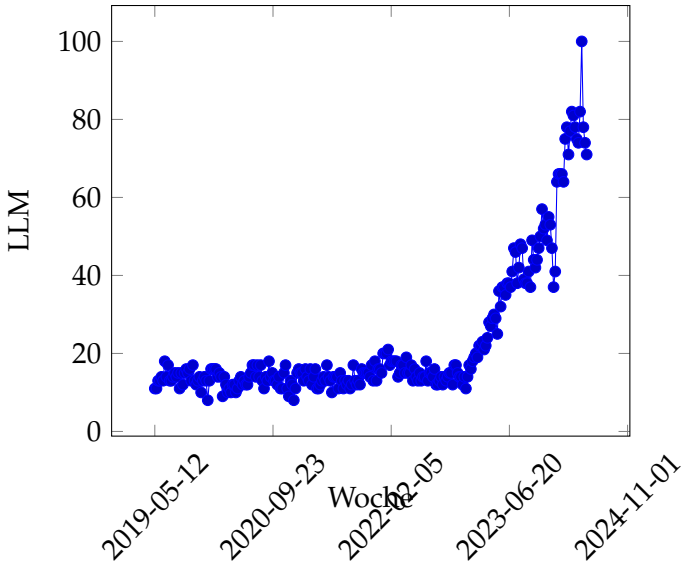


Abbildung 2.1 LLM Google Trends

Verlauf der letzten 5 Jahre darstellt, dass das Interesse an Large Language Models besonder stark im Dezember 2022 angestiegen ist und seitdem immer weiter steigt. Die Daten von Google Trends sind normalisiert zwischen 0 und 100 also können wird dadurch zwar keine genauen Angaben machen, wir sehen aber, dass das Wachstum stetig am steigen ist.

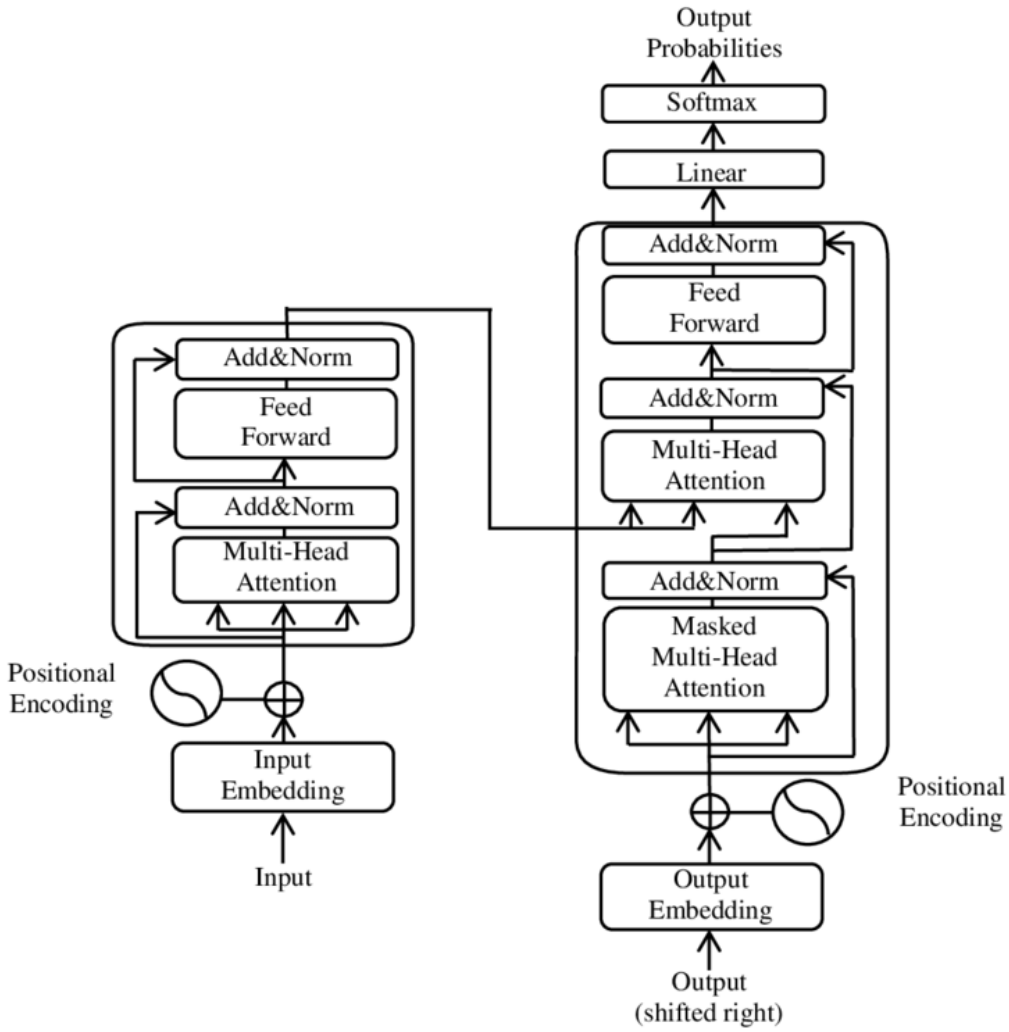


Abbildung 2.2 Transformer Architektur

2.3.1 Transformer

Die Technologie auf der die heutigen LLMs im Grunde basieren ist die sogenannte Transformer Technologie. Diese Architektur wurde im Research Paper Ättention is all you needïm Jahr 2017 von Google Forschern vorgestellt. Laut ihrer Forschung behaupteten sie, dass ihre neue Architektur signifikant weniger Zeit zum Training braucht, während es besser parallelisierbar ist und die Ergebnisse trotzdem besser sind. Nach 3.5 Tagen Training auf nur 8 Grafikkarten hat ihr Modell einen neuen Single Model Rekord aufgestellt in der WMT 2014 Englisch-zu-Französisch Übersetzungsaufgabe.

Von Yuening Jia - DOI:10.1088/1742-6596/1314/1/012186, CC BY-SA 3.0, https://commons.wikimedia.

2.3.2 Training

Der erste Schritt beim erstellen eines LLM nachdem die technischen Grundlagen stehen ist es, das Modell zu trainieren. Hierbei wurde der Transformer bereits entwickelt und wird im nächsten Schritt mit Daten trainiert.

2.3.3 Inference

Wenn man ein fertig trainiertes und finetuned Modell hat, kann man das Modell ausführen. Dieser Prozess nennt sich Inference. Hierbei werden die zwei Programme die Teil

2.4 Vektor Datenbanken

Vektor Datenkbanken sind die Datenbanken.

2.5 RAG

Eines der größten Probleme der LLMs heutzutage ist, dass die Informationen, die sie zum beantworten für Fragen benutzen, teilweise veraltet sind oder sehr allgemein. Eine Technologie, die versucht, dieses Problem zu beseitigen, ist die sogenannte RAG (Retrieval Augmented Generation).

2.6 Ragas

3 Konzeption

3.1 Auswahl der Chatmodelle

Nach der Analyse beginnt die Konzeption. Die erste Frage, die beantwortet werden muss, ist, welche Modelle werden benutzt. Es werden Modelle an zwei Stellen benötigt. Die erste Frage ist, welches Modell soll generell für den Chatbot benutzt werden. Hier gibt es ein paar Möglichkeiten. Die Einschränkungen die hier bestehen sind, da ein paar Confluence Pages Kundendaten beinhalten, daher sollte es keine API wie ChatGPT sein, bei der die Datensicherheit nicht besteht und Daten teilweise benutzt werden, um die Modelle weiter zu trainieren. Also ist die beste Möglichkeit, ein lokales LLM zu benutzen. Hier gibt es zur Zeit fast täglich neue Modelle. Zu den bekanntesten Open Source Modellen gehören die Modelle:

1. Mistral von Mistral AI
2. Llama von Meta AI
3. Gemma von Google

Wir werden im Kontext dieser Arbeit 5 verschiedene Modelle miteinander vergleichen. Die meisten der Open Source Modelle basieren aber auf den Modellen von Meta AI und Mistral AI, das heißt es sind finetuned Versionen von diesen. Ein Hub auf dem viele der Modelle veröffentlicht werden ist hugginface.co. Hier werden viele Open Source Modelle veröffentlicht und man kann sie downloaden und verschiedene Benchmarks, etc. einsehen. Einige der größeren Modelle wie beispielsweise Gemma und Llama3 wurden multilingual trainiert und verstehen in ihrer Grundversion bereits beide Sprachen, die wir brauchen.

3.2 Auswahl der Embedding Modelle

Die nächsten Modelle über die man sich Gedanken machen muss sind die sogenannten Embedding Modelle. Hier werden einmal die importierten Texte für die Vektor Datenbank in eine Vektor repräsentation umgewandelt.

3.3 Prompting

Ein wichtiger Teil, den man beim Erstellen von Modellen beachten muss, ist das Prompting. Es gibt hier zwei Aspekte, die man beachten muss.

3.4 Auswahl der Vektor Datenbank

Im nächsten Schritt wird die Art des Chat Modells ausgesucht. Hier gibt es einige Möglichkeiten. Eine Möglichkeit wäre es, mittels API auf ein Modell wie Chat-GPT 4 zuzugreifen. Die Probleme hierbei sind, dass die Modelle nicht speziell mit unseren benötigten APIs/Infos

vertraut sind. Wir könnten ein Modell suchen, dem wir unsere Daten schicken, aber das könnte teils Probleme mit Datenschutz geben. Durch diese Probleme fallen diese Optionen weg. Das heißt, das Modell muss lokal gehostet werden. Lokal heißt hierbei einfach auf einem Server von uns oder einem Server, bei dem man weiss, dass keiner auf die Daten zugreifen kann.

3.5 Architektur des Systems

Nachdem die Auswahl des Development Tools und des Models abgeschlossen ist, ist die nächste Frage, welche Architektur das gesamte System haben soll. Die Schnittstelle, über die der Nutzer später mit dem Chatbot kommunizieren soll, ist bestenfalls eine Schnittstelle zu Google Chat. Dies ist aber der unwichtigste Part an diesem Punkt. Notfalls kann man auch ein anderes Chat System anbinden, daher kümmern wir uns als erstes um die anderen Teile der Architektur.

Hierbei geht es um das Thema des Hinzufügens von neuem Wissen zum Chatbot. Das Problem bei einem trainierten Modell ist es, dass es keine neue Information ohne ein neues Training in seine Wissensdatenbank aufnehmen kann. Da sich die Daten in den jeweiligen APIs ständig ändern können, stellt das ein Problem dar. Hier ist aber nicht nur neue Information ein Problem, sondern auch geänderte alte. Woher soll der Chatbot wissen, dass sich irgendeine Information, die bereits in der Wissensdatenbank vorhanden ist, geändert hat. Für das Problem von neuen Informationen gibt es hier zwei Optionen. Das Modell, auf dem der Chatbot aufbaut, könnte neu trainiert werden, mithilfe der neuen Informationen. Hier sind die Fragen, wie oft es neu trainiert werden soll, wie lange dieser Prozess dauert und wie viel dieser Prozess kostet. Wir können das Modell nicht bei jedem neuen Update neu trainieren. Das würde zu lange dauern, aber das heisst dass es einen Zeitraum gibt in dem der Bot nicht die aktuellsten Informationen hat. Wir benutzen hier die vorher bereits erwähnte RAG in Kombination mit einer Vektor Datenbank.

4 Entwicklung

A Erstes Kapitel des Anhangs

Wenn Sie keinen Anhang benötigen, dann bitte einfach rausnehmen.

Literaturverzeichnis

[Ada20] E. Adamopoulou und L. Moussiades. Chatbots: History, Technology, and Applications. *Machine Learning with Applications*, 2:100006, Dez. 2020.

[Cha24] Chatbot. *Wikipedia*, Jan. 2024.

[Mor13] B. Morais. Can Humans Fall in Love with Bots? *The New Yorker*, Nov. 2013.

[Wei66] J. Weizenbaum. ELIZA—a Computer Program for the Study of Natural Language Communication between Man and Machine. Jan. 1966.